

文件编号: ITSS-09-02-02

版本: V1.0

天津通海信息技术有限公司

天津港引航中心引航信息系统及设备维 护项目数据清洗策略实施方案

编制人: 耿宁

编制时间: 2025.7.10

审核人: 常海霞

审核时间: 2025.7.10

批准人: 尹兆铮

审批时间: 2025.7.10

修订记录

日期	版本	变更说明	编写人	审核人	批准人
2025. 7. 10	V1. 0	新建文档	耿宁	常海霞	尹兆铮

目录

天津通海信息技术有限公司 1

天津港引航中心引航信息系统及设备维护项目数据清洗策略实施方案1

1. 总则 4

 1.1. 方案目的4

 1.2. 编制依据4

 1.3. 总体目标4

2. 数据清洗详细设计4

 2.1. 分域清洗策略 4

 2.1.1. 引航计划数据域 4

 2.1.2. 船舶动态数据域 5

 2.1.3. 引航员管理数据域 5

 2.1.4. 设备运维数据域 6

 2.1.5. 调度与资源数据域 6

 2.1.6. 费用与结算数据域 7

 2.1.7. 系统日志与接口数据域 7

 2.2. 技术架构与实施路径 7

3. 实施与管理规划 8

 3.1. 阶段化实施计划8

 3.2. 组织与职责分工8

 3.3. 关键交付物 9

4. 验收标准 9

5. 保障措施 9

6. 附则 10

1. 总则

1.1. 方案目的

为保障“天津港引航中心引航信息系统及设备维护项目”的数据质量与系统可靠性，特制定本数据清洗策略方案。本方案旨在系统性地规划与设计数据清洗工作，确保源自引航计划、船舶动态、引航员排班、设备运维、费用结算等业务系统的多源数据，在汇入核心平台前具备准确、完整、一致、及时的质量特征，从而支撑引航调度、资源分配、计费结算等核心业务实现预期价值。

1.2. 编制依据

本方案严格遵循《天津港引航中心引航信息系统及设备维护项目数据清洗策略需求分析报告》中提出的核心业务目标、质量要求与管理流程需求，是指导项目数据清洗工作实施的纲领性文件。

1.3. 总体目标

本方案致力于达成三大目标：

- 达成预设的数据质量关键绩效指标，满足引航作业安全规范及引航中心内部管理要求；
- 建立一套权责清晰、流程可控、持续改进的数据质量管理闭环；
- 交付高质量的数据资产及配套的治理能力，确保项目长效运营。

2. 数据清洗详细设计

2.1. 分域清洗策略

针对项目七大数据域的特征，实施差异化清洗。

2.1.1. 引航计划数据域

本域数据主要来源于引航申请、引航计划、引航工单、计划变更记录等，核心问题在于计划与执行脱节、变更记录缺失、引航时段冲突。

清洗策略包括：

建立引航计划与船舶AIS轨迹的关联校验，识别并标记计划未执行或严重偏离的异常工单；

对计划变更记录进行完整性校验，确保每次变更均有时间、原因、操作人记录；

检测同一引航员或拖轮在重叠时段内的排班冲突，自动预警并触发人工复核；

建立计划时间逻辑校验，确保引航开始时间、结束时间、前后作业衔接顺序合理。

2.1.2. 船舶动态数据域

本域数据包括AIS数据、船舶进出港记录、船舶档案、船舶预报信息等，主要存在船舶身份识别错误、动态信息延迟、船名/呼号不一致等问题。

清洗策略包括：

建立船舶主数据去重与匹配机制，基于MMSI码、IMO号、船名等关键字段识别并合并重复档案；

对AIS数据进行异常过滤，剔除位置漂移、速度异常等明显错误数据；

对船舶动态时间戳进行校验，确保动态记录的时间顺序合理，延迟数据标记并触发补录；

统一船舶识别标识规范，确保同一船舶在不同数据源中的编码一致。

2.1.3. 引航员管理数据域

本域数据包括引航员档案、资质证书、排班记录、考勤统计等，数据敏感性强，存在资质过期未更新、排班冲突与工时超限等问题。

清洗策略包括：

建立引航员资质有效期监控机制，临近过期自动预警，过期未更新自动标记并限制排班；

对排班记录进行冲突检测，确保同一时段不安排多任务，且工时不超过规定上限；

对引航员工号、姓名、证书编号进行一致性校验，与主数据比对，不一致的自动标记；

对考勤统计数据与排班计划进行交叉验证，识别异常签到或漏签情况。

2.1.4. 设备运维数据域

本域数据包括设备台账、维修记录、保养计划、故障报修单、巡检记录等，数据格式多样，存在设备编码不统一、维修记录缺失、保养计划逾期未执行等问题。

清洗策略包括：

建立设备主数据统一编码规范，确保同一设备在不同系统中的编码一致；

对维修记录的关键字段（设备编码、故障现象、维修措施、维修时间、维修人员）进行完整性校验，缺失字段标记并触发补录；

建立保养计划执行情况跟踪机制，对逾期未执行的保养计划自动预警并通知责任人；

对故障报修单进行分类归集，识别高频故障设备，为预防性维护提供数据支持；

对巡检记录进行时序校验，确保巡检周期符合预设标准，遗漏巡检自动标记。

2.1.5. 调度与资源数据域

本域数据包括拖轮调度记录、引航资源分配、泊位信息、航道状态等，存在资源冲突、调度指令与执行不一致、泊位编码不统一等问题。

清洗策略包括：

建立拖轮与引航任务的资源分配校验规则，检测同一拖轮在重叠时段内的任务冲突；

对调度指令与执行反馈进行比对，识别指令未执行、执行偏差等异常情况；

统一泊位编码规范，确保泊位信息在不同模块中的编码一致，不一致的自动映射；

对航道状态变更记录进行完整性校验，确保状态变更有时间、原因、操作人记录。

2.1.6. 费用与结算数据域

本域数据包括引航费收记录、结算凭证、应收账款、收费明细等，数据准确性要求极高，存在费率引用错误、计费吨位不一致、结算凭证日期混乱等风险。

清洗策略包括：

建立费率引用校验规则，自动比对费收记录中的费率与标准费率表，差异超阈值标记；

对计费吨位进行合理性校验，与船舶档案中的参考吨位对比，异常偏差自动预警；

建立凭证借贷平衡校验规则，不平凭证自动拦截并通知计费人员；

对结算凭证日期进行逻辑校验，确保凭证日期不晚于当前日期，不早于船舶作业日期；

对收费明细与费收记录进行一致性校验，确保金额匹配、计算正确。

2.1.7. 系统日志与接口数据域

本域数据来自各系统接口日志、数据库日志、用户操作日志等，数据体量大，关键告警易被淹没。

清洗策略包括：

制定统一的日志解析规范，准确提取时间、接口名称、错误码、操作人等关键字段；

建立规则引擎，从海量日志中实时过滤并归类错误、警告等关键事件；

对AIS接口、数据库连接等关键接口的调用失败、超时等情况进行统计和告警；

对用户异常操作（如多次登录失败、非授权访问尝试）进行识别和标记。

2.2. 技术架构与实施路径

采用“ETL批量清洗+实时校验”的混合架构：

1. 批量清洗：使用Kettle/DataX等ETL工具，对引航计划、设备运维、费用结算等核心业务数据进行定时批量清洗，执行数据标准化、去重、补全等操作；

- 2. 实时校验：在数据接入层部署轻量级校验规则，对实时性要求高的数据（如AIS动态、引航工单状态变更）进行实时完整性校验；
- 3. 任务调度：通过Apache Airflow进行清洗任务调度，管理依赖关系和执行顺序；
- 4. 监控看板：利用Grafana配置数据质量KPI看板，实时监控各项指标达成情况；
- 5. 规则配置：清洗规则力求实现配置化管理，通过配置文件或规则引擎驱动，提升可维护性。

3. 实施与管理规划

3.1. 阶段化实施计划

数据清洗工作将完全融入项目90天的总建设周期，分四阶段推进。

第一阶段（第1-30天）：规则设计与开发。完成各数据域清洗规则的详细设计、评审与核心代码开发。

第二阶段（第31-60天）：集成联调与试运行。与各业务系统对接联调，利用历史数据进行全流程试运行并优化。

第三阶段（第61-75天）：全量上线与监控。随系统正式上线启动全量数据清洗，并开启全天候质量监控。

第四阶段（第76-90天）：验收与交付。进行稳定性考核，输出最终质量报告，完成专项验收。

3.2. 组织与职责分工

角色	单位	职责
甲方业务负责人	天津港引航中心	负责清洗规则所涉及业务逻辑的最终评审与确认；参与验收测试
甲方技术负责人	天津港引航中心	负责本方案及技术交付物的评审；监督实施质量与进度
乙方项目经理	天津通海信息技术有限公司	负责方案整体推进，协调资源，定期汇报进展
乙方运维	天津通海信息技术有限公司	负责清洗规则的详细设计、代码开发

角色	单位	职责
实施工程师		、测试部署
双方联合验收组	双方	负责最终验收测试,确认KPI达成情况

3.3. 关键交付物

实施方需按阶段提交以下交付物：

- 1. 《详细数据清洗规则设计说明书》
- 2. 《数据清洗模块测试报告》
- 3. 《数据质量监控平台操作手册》
- 4. 《周期性数据质量分析报告》
- 5. 《数据清洗专项竣工报告》
- 6. 《数据清洗规则库》
- 7. 《数据质量日报/周报》
- 8. 《清洗过程审计日志》

4. 验收标准

数据清洗工作的验收以可量化、可验证的关键绩效指标为核心标准。在项目最终验收前，需提供连续15天的稳定运行数据，证明以下核心指标已持续达标：

指标类别	验收标准	数据来源
清洗有效性	核心业务字段填充率 ≥ 99%	系统统计
清洗有效性	关键业务数据准确率 ≥ 95%	抽样复核
处理时效性	95%的数据记录端到端清洗延迟 ≤ 10秒	监控平台
系统可靠性	数据清洗任务执行成功率 ≥ 99.9%	Airflow日志
过程可追溯	清洗过程日志完整率 100%	日志审计
流程可管理性	80%以上清洗规则可通过配置界面管理	系统验证

5. 保障措施

规则变更管理：为应对业务规则变化，建立《数据清洗规则变更管理流程》，任何清洗规则的变更需经甲方业务负责人书面审批，并在测试环境验证后方可上线。

数据可追溯：所有数据处理环节必须记录完整的数据血缘日志，确保从清洗后数据可追溯到原始数据，满足引航中心内部审计要求。

性能保障：清洗平台需通过高于当前数据峰值50%的压力测试，确保业务增长长期仍能稳定运行。

沟通机制：建立双周数据质量例会制度，由双方项目组共同参与，及时同步问题、评审报告并决策优化方向。

应急预案：制定清洗系统故障应急预案，明确故障发现、上报、处置、恢复的完整流程，确保故障发生时业务影响最小化。

6. 附则

本方案经甲方项目指导委员会评审通过后生效，即成为本项目数据清洗工作的最高执行依据。方案所有附件与本方案正文具有同等效力。