

文件编号: ITSS-09-02-03
版本: V1.0

天津通海信息技术有限公司

天津港引航中心引航信息系统及设备维 护项目数据清洗策略实施方法

编制人: 耿宁

编制时间: 2025.7.10

审核人: 常海霞

审核时间: 2025.7.10

批准人: 尹兆铮

审批时间: 2025.7.10

修订记录

日期	版本	变更说明	编写人	审核人	批准人
2025. 7. 10	V1. 0	新建文档	耿宁	常海霞	尹兆铮

目录

天津通海信息技术有限公司 1

天津港引航中心引航信息系统及设备维护项目数据清洗策略实施方法1

1. 文档概述 4

 1.1. 目的 4

 1.2. 适用范围 4

 1.3. 术语定义 4

2. 实施目标 5

 2.1. 数据质量目标 5

 2.2. 业务支撑目标 5

3. 具体实施策略 5

 3.1. 分域清洗实施要点 5

 3.1.1. 引航计划数据域 5

 3.1.2. 船舶动态数据域 6

 3.1.3. 引航员管理数据域 7

 3.1.4. 设备运维数据域 7

 3.1.5. 调度与资源数据域 8

 3.1.6. 费用与结算数据域 8

 3.1.7. 系统日志与接口数据域 9

 3.2. 技术工具与操作流程 9

4. 详细实施步骤 10

 4.1. 第一阶段：规则设计与环境准备（第1-30天） 10

 4.2. 第二阶段：集成联调与试运行（第31-60天） 10

 4.3. 第三阶段：全量上线与监控（第61-75天） 11

 4.4. 第四阶段：验收支持与知识转移（第76-90天） 11

5. 风险管理与质量控制 12

 5.1. 关键风险与应对 12

 5.2. 质量控制活动 12

6. 交付物清单 12

1. 文档概述

1.1. 目的

本文档旨在为“天津港引航中心引航信息系统及设备维护项目”提供具体、可操作的数据清洗实施方法。本方法严格遵循《数据清洗策略需求分析报告》的业务需求与《数据清洗策略方案》的技术架构，确保数据清洗工作能够高质量、高效率地落地执行，保障引航信息系统数据的准确性、一致性与时效性。

1.2. 适用范围

本方法适用于本项目所有数据源的清洗实施工作，具体包括但不限于以下七类数据域：

数据域	数据来源	主要问题
引航计划数据域	引航申请、引航计划、引航工单、计划变更记录	计划与执行脱节、变更记录缺失、引航时段冲突
船舶动态数据域	AIS数据、船舶进出港记录、船舶档案、船舶预报信息	船舶身份识别错误、动态信息延迟、船名/呼号不一致
引航员管理数据域	引航员档案、资质证书、排班记录、考勤统计	资质过期未更新、证书编号不一致、排班冲突与工时超限
设备运维数据域	设备台账、维修记录、保养计划、故障报修单、巡检记录	设备编码不统一、维修记录缺失、保养计划逾期未执行
调度与资源数据域	拖轮调度记录、引航资源分配、泊位信息、航道状态	资源冲突、调度指令与执行不一致、泊位编码不统一
费用与结算数据域	引航费收记录、结算凭证、应收账款、收费明细	费率引用错误、计费吨位不一致、结算凭证日期混乱
系统日志与接口数据域	应用日志、数据库日志、用户操作日志、接口调用日志	关键告警被淹没、日志格式不统一、接口调用失败未记录

1.3. 术语定义

数据清洗：指按照预定义的业务规则与技术逻辑，对原始数据进行检测、修正、转换或标记，以提升其准确性、完整性、一致性、唯一性与时效性的过程。

数据质量KPI：衡量数据清洗效果的关键量化指标，如准确率、填充率、延迟等。

数据血缘：记录数据从源头到最终形态的完整处理路径与变换关系。

2. 实施目标

2.1. 数据质量目标

通过实施本方法，确保清洗后数据达到以下量化标准：

准确性：核心业务字段值与其真实状态的一致性，核心业务数据准确率不低于95%。

完整性：关键数据采集无缺失，核心业务字段填充率不低于99%。

一致性：同一实体（如船舶、引航员、设备）在不同系统中的标识与属性完全统一，主数据一致率达到100%。

时效性：数据从产生到可用的端到端延迟（P95）不超过10秒。

唯一性：业务数据中的重复记录率低于0.1%。

2.2. 业务支撑目标

为引航计划编制、资源调度提供准确、及时的船舶动态和引航员/拖轮可用性数据

为引航作业调度、船舶进出港管理提供完整、一致的调度指令与执行反馈数据

为引航费收结算、财务对账提供准确、可靠的费收记录和凭证数据

为设备维护、保养计划提供完整、规范的维修和巡检记录

为引航员管理、排班决策提供准确、合规的资质证书和考勤数据

3. 具体实施策略

3.1. 分域清洗实施要点

3.1.1. 引航计划数据域

1. 实施要点：

建立引航计划与船舶AIS轨迹的关联校验规则，编写SQL脚本定期扫描异常工单（如计划已执行但无对应AIS轨迹、计划取消但仍占用资源）

对计划变更记录进行完整性校验，确保每次变更均有变更时间、变更原因、操作人记录

检测同一引航员或拖轮在重叠时段内的排班冲突，自动预警并生成冲突报告

建立计划时间逻辑校验规则，确保引航开始时间、结束时间、前后作业衔接顺序合理

2. 技术实现示例（SQL）：

```
sql
-示例：引航员排班冲突检测脚本
SELECT
  pilot_id,
  schedule_date,
  start_time,
  end_time,
  COUNT(*) as conflict_count
FROM pilot_schedule_table
WHERE schedule_date = '2025-07-10'
GROUP BY pilot_id, schedule_date, start_time, end_time
HAVING COUNT(*) > 1;
```

3.1.2. 船舶动态数据域

1. 实施要点：

建立船舶主数据去重与匹配机制，基于MMSI码、IMO号、船名等关键字段识别并合并重复档案

对AIS数据进行异常过滤，剔除位置漂移、速度异常（如>50节）、时间戳明显错误的的数据

对船舶动态时间戳进行校验，确保动态记录的时间顺序合理，延迟超过5分钟的数据标记并触发补录

统一船舶识别标识规范，确保同一船舶在不同数据源（AIS、引航申请、船舶档案）中的编码一致

2. 技术实现示例（SQL）：

```
sql
-示例：船舶主数据重复检测脚本
SELECT
  mmsi,
  ship_name,
  COUNT(*) as duplicate_count
FROM ship_master_table
GROUP BY mmsi
HAVING COUNT(*) > 1;
```

3.1.3. 引航员管理数据域

1. 实施要点：

建立引航员资质有效期监控机制，临近过期**30**天自动预警，过期未更新自动标记并限制排班

对排班记录进行冲突检测，确保同一时段不安排多任务，且单日工时不超过规定上限

对引航员工号、姓名、证书编号进行一致性校验，与主数据比对，不一致的自动标记

对考勤统计数据与排班计划进行交叉验证，识别异常签到或漏签情况

3.1.4. 设备运维数据域

1. 实施要点：

建立设备主数据统一编码规范，确保同一设备（如**VTS**设备、**AIS**基站、通信设备）在不同系统中的编码一致

对维修记录的关键字段（设备编码、故障现象、维修措施、维修时间、维修人员）进行完整性校验，缺失字段标记并触发补录

建立保养计划执行情况跟踪机制，对逾期未执行的保养计划自动预警并通知责任人

对故障报修单进行分类归集，按故障等级（紧急/重要/一般）自动标记，识别高频故障设备

对巡检记录进行时序校验，确保巡检周期符合预设标准，遗漏巡检自动标记

3.1.5. 调度与资源数据域

1. 实施要点：

建立拖轮与引航任务的资源分配校验规则，检测同一拖轮在重叠时段内的任务冲突

对调度指令与执行反馈进行比对，识别指令未确认、执行偏差等异常情况
统一泊位编码规范，确保泊位信息在不同模块中的编码一致，不一致的自动映射

对航道状态变更记录进行完整性校验，确保状态变更有时间、原因、操作人记录

3.1.6. 费用与结算数据域

1. 实施要点：

建立费率引用校验规则，自动比对费收记录中的费率与标准费率表，差异超阈值（如>5%）标记

对计费吨位进行合理性校验，与船舶档案中的参考吨位（总吨、净吨）对比，异常偏差自动预警

建立凭证借贷平衡校验规则，不平凭证自动拦截并写入异常表，通知计费人员

对结算凭证日期进行逻辑校验，确保凭证日期不晚于当前日期，不早于船舶作业日期

对收费明细与费收记录进行一致性校验，确保金额匹配、计算正确

2. 技术实现示例（SQL）：

```
sql
-示例：计费吨位合理性检测脚本
SELECT
    invoice_id,
    ship_id,
    billed_tonnage,
    reference_tonnage,
    ABS(billed_tonnage - reference_tonnage) / reference_tonnage as
    deviation_rate
FROM billing_detail_table
```



```
WHERE ABS(billed_tonnage reference_tonnage) / reference_tonnage > 0.1;
```

3.1.7. 系统日志与接口数据域

1. 实施要点：

制定统一的日志解析规范，使用正则表达式提取时间戳、接口名称、错误码、操作人等关键字段

建立规则引擎，从海量日志中实时过滤并归类错误、警告等关键事件

对AIS接口、数据库连接等关键接口的调用失败、超时等情况进行统计和告警

对用户异常操作（如多次登录失败、非授权访问尝试、非工作时间敏感操作）进行识别和记录

3.2. 技术工具与操作流程

1. 批量清洗：

使用Kettle/DataX等ETL工具，对引航计划、设备运维、费用结算等核心业务数据进行定时批量清洗

执行数据标准化、去重、补全等操作，按日批次运行

2. 实时校验：

在数据接入层部署轻量级校验规则，对实时性要求高的数据（如AIS动态、引航工单状态变更）进行实时完整性校验

采用规则引擎（如Drools）管理校验规则，实现规则与代码解耦

3. 任务调度：

通过Apache Airflow进行清洗任务调度，管理依赖关系和执行顺序

设置失败重试、告警通知机制，确保任务可靠性

4. 监控看板：

利用Grafana配置数据质量KPI看板，实时监控各项指标达成情况

设置阈值告警，指标异常时通过邮件、企业微信通知相关人员

5. 规则配置：

清洗规则以JSON配置文件形式存储，通过内部管理界面进行发布、更新与回滚

建立规则版本管理机制，确保规则变更可追溯

4. 详细实施步骤

4.1. 第一阶段：规则设计与环境准备（第1-30天）

1. 数据源对接：

与各业务系统负责人确认数据接口协议，完成引航计划、船舶动态、引航员排班、设备运维等模块的接入调试

梳理数据字典，明确各数据域的关键字段和业务规则

2. 规则细化开发：

依据《数据清洗策略实施方案》中的规则设计要点，编写具体的清洗代码与配置文件

为每类清洗规则编写单元测试用例，确保规则正确性

3. 测试环境部署：

搭建与生产环境一致的测试集群，部署清洗程序与相关依赖组件
配置任务调度和监控系统

4. 交付物：

《详细数据清洗规则说明书》

《测试环境部署报告》

清洗规则单元测试用例及结果

4.2. 第二阶段：集成联调与试运行（第31-60天）

1. 模块集成：

将清洗模块与各业务系统进行联调，确保数据通路畅通
验证清洗程序对接入数据的处理效果

2. 试运行与调优：

使用历史数据开展至少15天的试运行，监控清洗效果

根据业务部门（引航调度科、设备管理科、计费科等）的反馈调整规则参数

记录试运行期间的数据质量问题和处理情况

3. 交付物:

《数据清洗模块集成测试报告》

《试运行数据质量分析报告》

试运行期间问题处理记录

4.3. 第三阶段：全量上线与监控（第61-75天）

1. 生产环境部署:

将经测试验证的清洗程序与配置部署至生产环境

执行数据全量清洗，确保历史数据质量

2. 监控体系启用:

全面开启数据质量监控看板与告警，实施7x24小时运行监控

建立数据质量日报机制，每日推送质量报告

3. 交付物:

《生产环境部署手册》

《数据质量监控看板使用指南》

数据质量日报模板

4.4. 第四阶段：验收支持与知识转移（第76-90天）

1. 稳定性运行:

保障清洗系统连续稳定运行，收集验收所需的KPI数据

确保连续15天各项KPI持续达标

2. 文档与培训:

整理全部实施文档，包括设计文档、配置说明、操作手册等

向甲方运维团队提供一次系统性的操作培训，确保知识有效转移

3. 交付物:

《数据清洗系统运维手册》

《培训记录》（含签到表、培训材料）

《最终数据清洗竣工报告》（含KPI达标证明）

5. 风险管理与质量控制

5.1. 关键风险与应对

风险类型	风险描述	应对措施
规则逻辑错误	清洗规则逻辑错误导致数据被错误修改或删除	所有清洗规则上线前必须通过业务逻辑评审与数据样本测试,在测试环境充分验证;变更需走审批流程,并在测试环境验证后方可上线
数据丢失与失真	清洗过程中数据丢失或失真,无法追溯	清洗前对原始数据永久备份;清洗过程中记录完整数据血缘日志,确保任何数据都可追溯还原
系统性能瓶颈	清洗系统成为数据处理瓶颈,影响业务时效	清洗系统需通过至少1.5倍业务峰值压力的性能测试;设置弹性伸缩策略,监控系统负载
业务规则变更	业务规则变化导致清洗规则失效	建立《数据清洗规则变更管理流程》,与业务部门建立沟通机制,及时响应规则变更需求
沟通与协作	与甲方沟通不畅,需求理解偏差	与甲方建立双周例会制度,同步进展、评审报告;使用协同平台管理数据质量问题工单

5.2. 质量控制活动

代码审查：所有清洗脚本与配置变更需经过同级评审。

测试用例：为每类清洗规则编写对应的单元测试与集成测试用例。

质量门禁：在CI/CD流水线中设置质量门禁，测试覆盖率、规则验证通过率不达标则禁止发布。

6. 交付物清单

本实施方法要求产出以下具体交付物，作为工作完成的证据与后续运维的依据：

- 《详细数据清洗规则说明书》
- 《数据清洗模块源代码及配置库》
- 《测试报告》（单元测试、集成测试、性能测试）

4. 《生产环境部署与配置文档》
5. 《数据质量监控看板与告警规则说明》
6. 《数据清洗系统运维手册》
7. 《最终数据清洗竣工报告》（必须附有连续**15天KPI**达标的数据截图与说明）